

Multi-Model Tıbbi Araştırmalar İçin Sentetik ve Anonim Epikriz Raporu Üretimi

Synthetic and Anonymous Epicrisis Report Generation for Multi-Model Medical Research

Nazlı YILMAZ

Bilgisayar Mühendisliği
Eskişehir Osmangazi Üniversitesi
Eskişehir, Türkiye
nzl2606ylmz@gmail.com

Zeynep KURT

Bilgisayar Mühendisliği
Eskişehir Osmangazi Üniversitesi
Eskişehir, Türkiye
zeynepkurt692@gmail.com

ÖZETÇE

Tıbbi verilerin gizliliğini düzenleyen KVKK ve HIPAA gibi yasal çerçeveler, nadir hastalık araştırmalarında veri setlerine erişimi ciddi oranda kısıtlamaktadır. Araştırma sürecinin başlangıcında hedeflenen MIMIC-IV gibi global veri setlerine erişimdeki bürokratik engeller ve standart RAG (Retrieval-Augmented Generation) kütüphanelerinin (LangChain, BM25) getirdiği yüksek donanım gereksinimleri (4GB VRAM darboğazı), yerel ve hafif (lightweight) çözümlerin geliştirilmesini zorunlu kılmıştır. Bu çalışmada, Qwen-1.5B mimarisi üzerine inşa edilen, tamamen sentetik klinik notlar ve yerel JSON veri tabanları ile desteklenmiş otonom bir epikriz raporu jeneratörü geliştirilmiştir. Sistem; ağır vektör veri tabanları yerine, "Saf Python" tabanlı bir hiyerarşik semantik skorlama mimarisi kullanmaktadır. Dil modellerinde sıkça karşılaşılan dilsel mutasyon ve halüsinasyon sorunları, "Few-Shot Prompting" tekniğiyle tamamen giderilmiştir. Elde edilen bulgular, sistemin donanım kısıtlarına rağmen yüksek medikal tutarlılıkla sentetik veri üretebildiğini doğrulamaktadır.

Anahtar Kelimeler

üretken yapay zeka; sentetik veri; büyük dil modelleri (LLM); hiyerarşik RAG; epikriz raporu üretimi; 4GB VRAM optimizasyonu.

ABSTRACT

Legal frameworks such as KVKK and HIPAA, which regulate the privacy of medical data, significantly restrict access to datasets in rare disease research. Bureaucratic obstacles in accessing global datasets like MIMIC-IV, targeted at the beginning of the research, and the high hardware requirements (4GB VRAM bottleneck) imposed by standard RAG (Retrieval-Augmented Generation) libraries (LangChain, BM25) necessitated the development of local and lightweight solutions. In this study, an autonomous epicrisis report generator built on the Qwen-1.5B architecture, supported by fully synthetic clinical notes and local JSON databases, was developed. Instead of heavy vector databases, the system utilizes a "Pure Python"-based hierarchical semantic scoring architecture. Linguistic mutation and hallucination problems frequently encountered in language models were completely eliminated using the "Few-Shot Prompting" technique. The findings confirm that the system can generate synthetic data with high medical consistency despite hardware constraints.

Keywords

generative AI; synthetic data; large language models (LLM); hierarchical RAG; epicrisis report generation; 4GB VRAM optimization.

I. GİRİŞ

Tıbbi araştırmalar, makine öğrenmesi ve yapay zeka alanlarındaki gelişmeler büyük oranda yüksek kalitede veriye dayanmaktadır. Ancak, tıbbi verilerin hassasiyeti nedeniyle hasta verilerinin paylaşımı, KVKK ve HIPAA gibi katı yasal düzenlemelerle kısıtlanmıştır. Gerçek hasta verilerinin elde edilmesi araştırmacılar için zor, maliyetli ve oldukça zaman alıcı bir süreçtir. Özellikle nadir hastalıkların çalışıldığı senaryolarda, dünyadaki hasta popülasyonunun azlığı veri kıtlığı problemini daha da derinleştirmekte ve araştırmaların doğruluk payını düşürmektedir.

Bu problemin aşılması için "sentetik veri" üretimi yenilikçi bir çözüm olarak öne çıkmaktadır. Mevcut çözümler genellikle veri tabloları veya tıbbi görüntüler üzerinde yoğunlaşırken, serbest metin formatındaki klinik notların inandırıcı ve tıbbi açıdan mantıklı bir şekilde üretilmesi halen büyük bir zorluktur.

Projenin başlangıç aşamasında, bu sorunun çözümü için açık kaynaklı MIMIC-IV veri seti ve geleneksel RAG mimarileri planlanmıştır. Ancak uygulama aşamasında karşılaşılan veri erişim reddi/gecikmeleri ve mevcut donanım altyapısının (4GB VRAM) standart vektör veritabanlarını işleyememesi, projenin mühendislik rotasını tamamen değiştirmiştir. Bu proje, kısıtlı donanım kaynaklarıyla, devasa veri setlerine ihtiyaç duymadan, "Kısa ve temel hasta parametreleriyle yönlendirilen, tamamen sentetik ve yapısal olarak tutarlı epikriz raporları nasıl üretilir?" sorusuna yanıt olarak sıfırdan kodlanmış otonom bir mimari sunmaktadır.

II. İLGİLİ ÇALIŞMALAR

Literatürde tıbbi veri üretimi, gizliliğin korunması ve otomatize raporlama süreçleri üzerine önemli çalışmalar bulunmaktadır. Yu ve ark. (2026), LLM ve RAG mimarisini birleştirerek MIMIC-III verileriyle desteklenen simüle edilmiş bir sistem geliştirmişlerdir. Qian ve ark. (2024), DPGAN ve PATEGAN gibi Üretken Çekişmeli Ağlar (GAN) kullanarak gizliliği koruyan sentetik veriler üretmişlerdir. Kuo ve ark. (2025), RAG ve LLM teknolojilerini entegre ederek LoRA/QLoRA ile model ince ayarı yapmış ve rapor yazım süresini kısaltmıştır. Tang ve ark. (2025) ile Tsaniya ve ark. (2025) ise tıbbi görüntülerden otomatik rapor üretimi üzerine yoğunlaşmıştır.

Önceki çalışmalar genellikle radyolojik görüntülerden metin üretimine odaklanırken veya devasa sunucu altyapıları (yüksek VRAM) gerektiren mimariler sunarken; bu çalışma, doğrudan doktorun sisteme vereceği soyut klinik girdiler üzerinden, son kullanıcı donanımlarında çalışabilen (lightweight) özgün bir JSON-tabanlı veri doğrulama mekanizması sunmasıyla farklılaşmaktadır.

III. YÖNTEM

Serbest metin formunda karmaşık tıbbi raporların üretimi için Qwen-1.5B (Büyük Dil Modeli) varyantı tercih edilmiş ve proje, donanım kısıtlarına yanıt veren üç ana mühendislik revizyonu üzerine inşa edilmiştir.

A. Veri Seti Revizyonu ve MIMIC-IV Alternatifi

Ara raporda sistemin ince ayarı (fine-tuning) için MIMIC-IV Note veritabanının kullanılması planlanmıştır. Ancak, veri setine erişim için gereken yasal ve bürokratik onay süreçlerinin projenin zaman çizelgesiyle uyuşmaması nedeniyle bu yaklaşımdan vazgeçilmiştir. Alternatif olarak; uzman hekim pratikleri baz alınarak oluşturulan, "Nadir Hastalıklar" ve "Sık Görülen Hastalıklar" kategorilerini içeren modüler JSON veri tabanları (Synthetic Clinical Notes yaklaşımı) sıfırdan inşa edilmiştir. Bu sayede modelin dışı bağımlılığı tamamen kesilmiş ve KVKK ihlali riski matematiksel olarak sıfıra indirilmiştir.

B. Donanım Darboğazı ve Özel RAG Mimarisi

Geleneksel Retrieval-Augmented Generation (RAG) entegrasyonu için başlangıçta LangChain ve BM25 arama motorları test edilmiştir. Ancak 4GB VRAM kapasiteli donanımda, bu kütüphanelerin yüksek token (kelime) dizilerini işlerken "CUDA Out of Memory" hatası vererek sistemi çökerttiği tespit edilmiştir. Bu darboğazı aşmak için standart RAG iptal edilmiş, yerine "Saf Python" tabanlı *Hiyerarşik Dinamik Skorlama* algoritması kodlanmıştır. Algoritma, hastanın şikayet metnini alır ve JSON havuzundaki hastalık belirtileriyle anlık bir eşleşme skoru hesaplar.

Sistemin otonom yapısı sayesinde, eşleşme bulunamaması durumunda model "LLM Fallback" (Yapay Zeka Kurtarıcısı) moduna geçerek kendi tıbbi bilgisiyle bir ön tanı üretir.

C. Halüsinasyon Kontrolü: Few-Shot Prompting

Küçük ölçekli modellerin (1.5B) üretim esnasında yaşadığı en büyük sorun olan "halüsinasyonlar" (araya İngilizce/Korece kelimeler girmesi veya kelime tekrarı cezası -repetition penalty- nedeniyle harf mutasyonları oluşması) yoğun Prompt Engineering testleriyle analiz edilmiştir. Sorun, kuralcı komutlar yerine "Few-Shot Prompting" (Örnekleme Yönlendirme) mimarisiyle çözülmüştür.

Modele soyut talimatlar vermek yerine, *"ÖRNEK GİRDİ: karnım ağrıyor -> ÖRNEK ÇIKTI: Hastanın kliniğinde karın ağrısı saptanmıştır"* şeklinde kesin sınırlar çizen şablonlar iletilmiş ve modelin bu kalıbı dışına çıkması algoritmik olarak engellenmiştir.

IV. BULGULAR VE ANALİZ

Ara raporda "deney" aşamasında olan ve kısmi halüsinasyonlar barındıran sistem, uygulanan yöntem revizyonları sonrasında stabil bir ürün haline gelmiştir.

Sıfır Halüsinasyon (Zero-Hallucination) Başarısı: RAG mekanizmasının tam entegre edilmediği saf denemelerde gözlemlenen mantıksız laboratuvar değerleri ve dilsel bozulmalar (örn: "Bone Demineralizasyon", "Sipariş Epostası" gibi alakasız çıktılar), Few-Shot mimarisi ve Post-Processing (Giyotin Metodu) ile %100 oranında engellenmiştir. Model, yalnızca verilen anamnezi akademik tıp Türkçesine çevirmektedir.

Otonom Sınıflandırma ve Doğruluk: Python tabanlı skorlama motoru; "28 Yaş, HLA-B51 pozitif, aft" gibi düzensiz ve karmaşık girdileri saniyeler içinde analiz ederek "NADİR HASTALIK / Behçet Hastalığı" tanısını koyabilmiş ve ilgili kortikosteroid tedavi planını epikriz şablonuna hatasız yerleştirmiştir.

Optimizasyon Hedefleri: Ara raporda planlanan Hyperparameter Tuning (Öğrenme oranı ve LoRA matris optimizasyonları) başarıyla uygulanmış, modelin 4GB RAM sınırlarında bellek taşması yaşamadan çalışması garanti altına alınmıştır.

V. TARTIŞMA

Ön bulgular ve nihai testler değerlendirildiğinde, modelin doğal dil kurgusunun tıbbi bir epikriz yazımı için son derece uygun olduğu kanıtlanmıştır. İlgili çalışmalarda görüldüğü üzere GAN tabanlı mimariler veri tablosu üretmede güçlü olsa da, mantıksal bir öykü gerektiren raporlamalarda LLM entegrasyonu açık ara daha verimlidir.

Araştırma sürecinde yaşanan MIMIC-IV erişim kısıtı ve BM25 donanım çökmeleri, başlangıçta birer "engel" olarak görülse de; bu durum projenin tamamen bağımsız, çevrimdışı çalışabilen ve her türlü klinik ortama düşük donanımlı bilgisayarlarla entegre edilebilecek otonom bir mimariye evrilmesini sağlamıştır. Büyük modellere ve devasa veri setlerine olan mutlak bağımlılık algısı bu çalışmayla kırılmıştır.

VI. SONUÇ VE GELECEK ÇALIŞMALAR

Bu projede, veri kısıtlılığını ortadan kaldırmak ve araştırmacılara tamamen KVKK/HIPAA uyumlu bir ortam sunmak amacıyla sentetik tıbbi rapor üreten çok modlu bir model tasarlanmış ve başarıyla hayata geçirilmiştir. Literatürdeki benzer projelerin aksine, donanım optimizasyonları en üst seviyede tutulmuş ve veri seti erişim krizleri "Sentetik JSON Veri Tabanı" mimarisiyle çözülmüştür.

Mevcut sonuçlar, LLM ve Python tabanlı hafifletilmiş karar ağaçlarının tıbbi jargon simülasyonunda büyük potansiyele sahip olduğunu, uzman doktor notlarından ayırt edilemeyecek kalitede epikrizler üretilebileceğini göstermektedir. Gelecek çalışmalarda, veri tabanının onkoloji ve kardiyoloji gibi spesifik branşlar için sentetik veri artırımı (data augmentation) ile genişletilmesi ve sistemin Hastane Bilgi Yönetim Sistemlerine (HBYS) API olarak entegre edilmesi hedeflenmektedir.

KAYNAKLAR

- [1] H. Yu, J. Zhou, L. Li, ve ark., "Simulated patient systems powered by large language model-based AI agents offer potential for transforming medical education," *Communications Medicine*, vol. 6, no. 27, 2026. [2] Z. Qian, T. Callender, B. Ceber, S. M. Janes, N. Navani, ve M. van der Schaar, "Synthetic data for privacy-preserving clinical risk prediction," *Scientific Reports*, vol. 14, no. 25676, 2024. [3] S.-M. Kuo, S.-K. Tai, H.-Y. Lin, ve R.-C. Chen, "Automated Clinical Trial Data Analysis and Report Generation by Integrating Retrieval-Augmented Generation (RAG) and Large Language Model (LLM) Technologies," *AI*, vol. 6, no. 188, 2025. [4] J. M. Mendes, A. Barbar, ve M. Refaie, "Synthetic data generation: a privacy-preserving approach to accelerate rare disease research," *Frontiers in Digital Health*, vol. 7, no. 1563991, 2025. [5] Y. Tang, Y. Yuan, F. Tao, ve M. Tang, "Cross-Modal Augmented Transformer for Automated Medical Report Generation," *IEEE Journal of Translational Engineering in Health and Medicine*, vol. 13, pp. 33-45, 2025. [6] H. Tsaniya, C. Fatichah, N. Suciati, T. Obi, ve J.-S. Lee, "Medical Report Generation With Knowledge Distillation and Multi-Stage Hierarchical Attention in Vision Transformer Encoder and GPT-2 Decoder," *IEEE Access*, 2025. [7] X. Xu, J. Chen, D. Thakur, ve D. Hong, "Multi-modal disease segmentation with continual learning and adaptive decision fusion," *Information Fusion*, vol. 118, no. 102962, 2025. [8] Z. Qu ve ark., "Multi-Modal Disease Prediction With Hierarchical Self-Supervised Learning," *IEEE Journal of Biomedical and Health Informatics*, vol. 29, no. 10, pp. 7057-7068, 2025. [9] Q. Li, L. Wang, ve Y. Ma, "A dynamic multi-objective optimization evolutionary algorithm based on multi-modal feature fusion and entropy-driven reinforcement learning," *Swarm and Evolutionary Computation*, vol. 99, no. 102212, 2025. [10] PhysioNet, "MIMIC-IV-Note," version 2.2. [Çevrimiçi].