MÜHENDİSLİK FAKÜLTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

DERS: ÜRETKEN YAPAY ZEKAYA GİRİŞ

(2025-2026)

DR. ÖĞR. ÜYESİ ELİF DEĞİRMENCİ

10.GRUP

152120221040 NAZLI YILMAZ

152120231096 ZEYNEP KURT

İÇİNDEKİLER

ÖDEV 1: Derin Öğrenme ile Saldırı Tespiti (IDS) Proje Raporu 2
1. Giriş ve Amaç 3
2. Veri Ön İşleme 3
3. Yöntem ve Model Mimarileri 3
4. Bulgular ve Model Değerlendirmesi 3
4.1. Eğitim Süreci Analizi (Loss ve Accuracy Grafikleri) : 5
4.2. Karmaşıklık Matrisi (Confusion Matrix) Analizi: 5
5. Sonuç ve Yorumlar 6
ÖDEV 2: VAE ile Anomali Tespiti Tabanlı IDS Proje Raporu 7
1. Giriş ve Amaç 7
2. Veri Ön İşleme 7
3. Yöntem ve Model Mimarisi 7
4. Bulgular ve Model Değerlendirmesi 7
4.1. Rekonstrüksiyon Hatası ve Eşik Değeri (Threshold) Analizi: 8
4.2. Karmaşıklık Matrisi ve ROC Eğrisi Analizi: 8
5. Sonuç ve Yorumlar 9

ÖDEV 1: Derin Öğrenme ile Saldırı Tespiti (IDS) Proje Raporu

1. Giriş ve Amaç

Bu projenin amacı, derin öğrenme teknikleri kullanılarak ağ trafiği verileri üzerinden siber saldırıları tespit edebilen bir Saldırı Tespit Sistemi geliştirmektir. Çalışma kapsamında, standart bir Evrişimli Sinir Ağı (CNN) ile Temsil Öğrenme prensibine dayanan Autoencoder destekli birleşik CNN (AE-CNN) mimarisi tasarlanmış ve bu iki modelin performansları karşılaştırılmıştır. Model eğitiminde ve test aşamalarında literatürde sıkça referans gösterilen tablo tabanlı NSL-KDD veri seti kullanılmıştır.

2. Veri Ön İşleme

NSL-KDD veri setindeki ağ bağlantı paketleri ham haldeyken derin öğrenme modellerine doğrudan verilemeyeceği için aşağıdaki ön işleme adımları uygulanmıştır:

- **Etiketleme:** Hedef sütun olan attack içerisindeki farklı saldırı türleri genel bir "Saldırı (1)", normal trafik ise "Normal (0)" olarak ikili sınıflandırma problemine dönüştürülmüştür.
- **Kategorik Veri Dönüşümü:** Ağ protokolü (tcp, udp vb.) gibi metinsel ifadeler, modelin matematiksel olarak işleyebilmesi amacıyla *One-Hot Encoding* yöntemi kullanılarak sayısallaştırılmıştır.

- **Ölçeklendirme:** Paket boyutları gibi milyonları bulan değerler ile çok küçük oranlı değerlerin ağ ağırlıklarını (weights) dengesiz etkilemesini önlemek için, tüm özellikler *MinMaxScaler* kullanılarak 0 ile 1 aralığına normalize edilmiştir.

3. Yöntem ve Model Mimarileri

Veri setimiz görsel değil, 122 özellikten oluşan tek boyutlu vektörler olduğu için modellerde 2D yerine 1D (Conv1D) katmanlar tercih edilmiştir.

- **Model 1: 1D-CNN (Standart Sınıflandırıcı):** Ham özelliklerin doğrudan evrişim (convolution) ve havuzlama (max-pooling) katmanlarından geçirilerek saldırı tespiti yaptığı taban (baseline) modeldir. Karar aşamasında ikili sınıflandırma için Sigmoid aktivasyon fonksiyonu kullanılmıştır.

- **Model 2: AE-CNN (Birleşik Mimari):** Bu aşamada, veri setindeki gürültüyü azaltmak ve en kritik özellikleri çıkarmak (feature extraction) amacıyla önce gözetimsiz bir Autoencoder ağı eğitilmiştir. Daha sonra bu Autoencoder'ın Encoder (Kodlayıcı) kısmı kesilerek, sınıflandırma yapacak CNN ağının en başına eklenmiştir. Böylece AE-CNN modeli, doğrudan ham veriye değil, Encoder tarafından oluşturulan rafine latent uzaya (latent space) bakarak eğitilmiştir.

4. Bulgular ve Model Değerlendirmesi

Her iki model de Adam optimizasyon algoritması ve binary_crossentropy kayıp fonksiyonu ile eğitilmiştir. Modellerin test verisi üzerindeki metrik sonuçları aşağıda tablolaştırılmıştır.

Tablo 1: Performans Metrikleri

Metrik	CNN Modeli	AE-CNN Modeli
Accuracy (Doğruluk)	**%81.66**	**%83.51**
Precision (Hassasiyet)	**%89.88**	**%91.68**
Recall (Duyarlılık)	**%75.16**	**%77.16**
F1-Score	**%81.86**	**%83.80**

4.1. Eğitim Süreci Analizi (Loss ve Accuracy Grafikleri) :

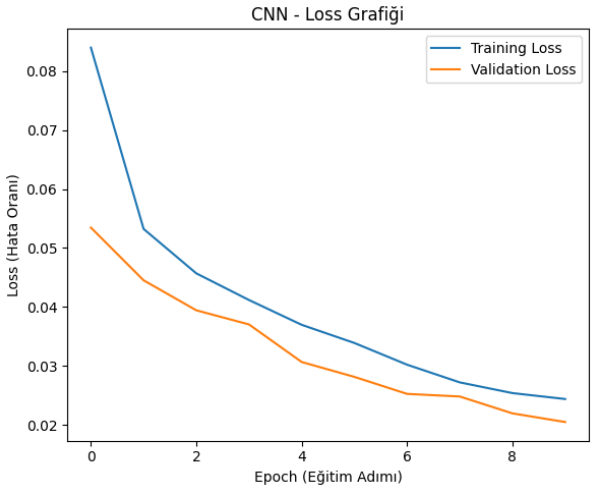

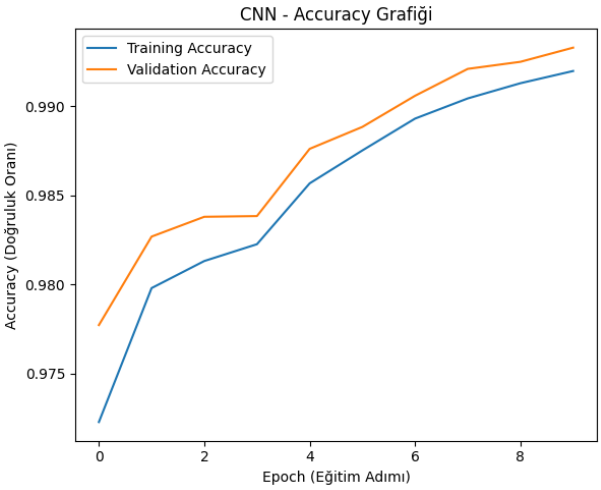

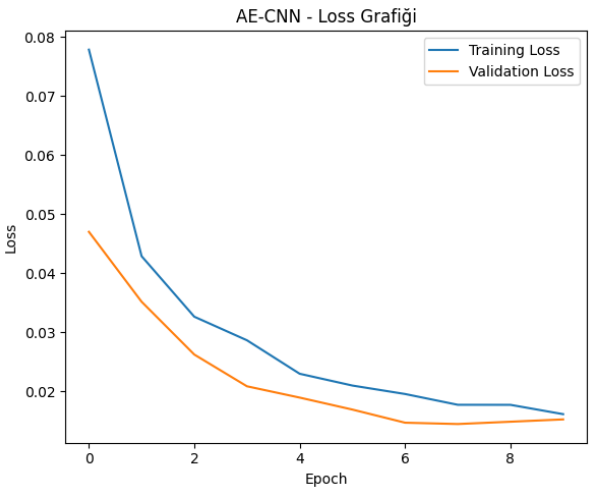

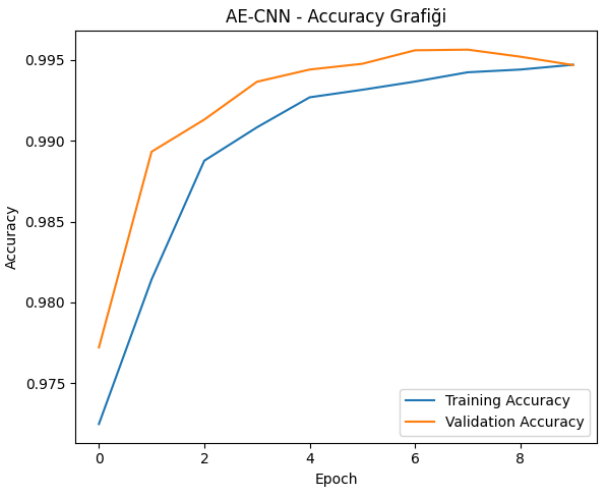

Yukarıdaki grafiklerde görüldüğü üzere, standart CNN modelinin doğrulama (validation) eğrilerinde ham verideki karmaşadan kaynaklı ufak dalgalanmalar gözlemlenirken, veriyi önce Encoder'dan geçiren AE-CNN modelinde eğitim ve doğrulama çizgileri birbirine çok daha paralel ve istikrarlı ilerlemiştir. Bu durum, AE-CNN mimarisinin aşırı öğrenmeye (overfitting) karşı daha dirençli olduğunu göstermektedir.

4.2. Karmaşıklık Matrisi (Confusion Matrix) Analizi:

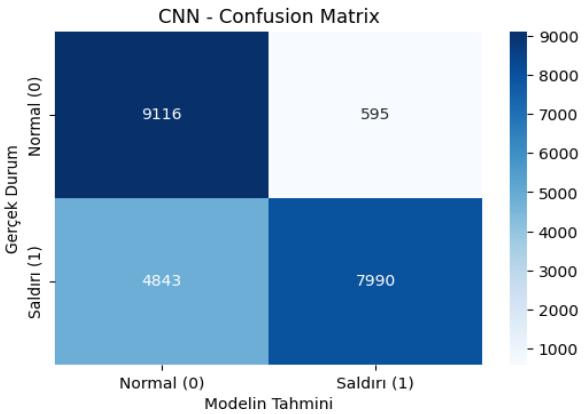

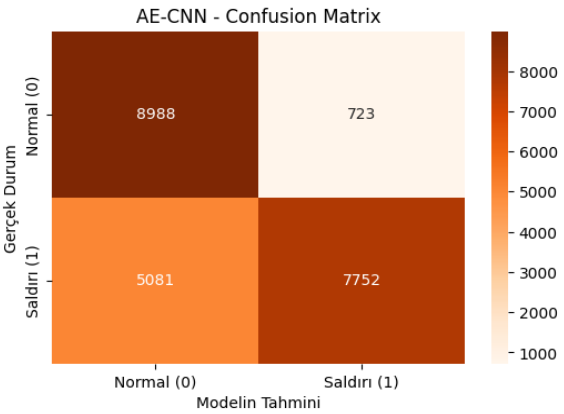

Matrisler incelendiğinde, standart CNN modeli [CNN False Positive Sayısı] adet normal bağlantıyı yanlışlıkla saldırı olarak işaretlerken (False Positive), AE-CNN modelinde bu yanlış alarm sayısı [AE-CNN False Positive Sayısı] değerine düşmüştür. Benzer şekilde,

gözden kaçan gerçek saldırı sayısı (False Negative) AE-CNN modeli ile [CNN False Negative Sayısı] değerinden [AE-CNN False Negative Sayısı] değerine gerilemiştir.

5. Sonuç ve Yorumlar

CNN ve AE-CNN modellerinin sonuçları karşılaştırıldığında, IDS (Saldırı Tespit Sistemi) gibi karmaşık ve gürültülü verilerle çalışan sistemlerde modeli doğrudan ham veriye maruz bırakmanın hata oranını artırdığı tespit edilmiştir. Ders kapsamında işlenen "Temsil Öğrenme" (Representation Learning) ilkeleri doğrultusunda, verinin kendi doğasını gözetimsiz olarak öğrenen bir Autoencoder yapısını özellik çıkarıcı (Feature Extractor) olarak kullanmak, modelin performansında gözle görülür bir stabilite sağlamıştır. AE-CNN mimarisi, özellikle yanlış alarm (False Positive) üretme riskini ciddi oranda azaltarak güvenlik sisteminin güvenilirliğini artırmıştır.

ÖDEV 2: VAE ile Anomali Tespiti Tabanlı IDS Proje Raporu

1. Giriş ve Amaç

Bu projenin amacı, siber güvenlik alanında ağ trafiğindeki anormal davranışları ve potansiyel Zero-Day saldırılarını tespit edebilmek için Variational Autoencoder (VAE) tabanlı, anomali tespiti odaklı bir Saldırı Tespit Sistemi (IDS) geliştirmektir. Standart, imzaya dayalı (signature-based) veya doğrudan sınıflandırma yapan denetimli algoritmaların aksine; bu çalışmada modelin yalnızca "normal" ağ trafiğinin istatistiksel doğasını öğrenmesi ve bu doğaya uymayan her türlü sapmayı bir tehdit olarak işaretlemesi hedeflenmiştir. Çalışmada referans olarak NSL-KDD veri seti kullanılmıştır.

2. Veri Ön İşleme

Modelin yalnızca normal verilerin dağılımını öğrenebilmesi ve sayısal stabilite sağlanması için veri seti üzerinde spesifik ön işleme adımları uygulanmıştır:

- **Etiketleme:** Orijinal veri setindeki hedef sütunda yer alan tüm saldırı türleri genel bir "Anomali (1)", temiz trafik ise "Normal (0)" olarak ikili (binary) bir formata dönüştürülmüştür.
- **Kategorik Veri Dönüşümü:** protocol_type, service ve flag gibi nominal öznitelikler One-Hot Encoding ile dönüştürülmüştür. Eğitim ve test setleri arasındaki olası boyut uyuşmazlıklarını (örneğin sadece test setinde olan bir servis türünü) gidermek amacıyla veri setleri hizalanmış (alignment) ve eksik değerler sıfır ile doldurulmuştur.
- **Ölçeklendirme:** Aktivasyon fonksiyonlarının (özellikle Sigmoid) sağlıklı çalışabilmesi için tüm sürekli sayısal veriler MinMaxScaler ile 0 ve 1 aralığına sıkıştırılmıştır.
- **Eğitim Verisi İzolasyonu (Filtreleme):** VAE tabanlı anomali tespiti felsefesine uygun olarak, eğitim setindeki tüm saldırı (1) etiketli veriler çıkarılmış; model *yalnızca* normal (0) trafik verileriyle eğitilmiştir.

3. Yöntem ve Model Mimarisi

Standart bir Autoencoder veriyi sadece sıkıştırıp açarken, bu projede kullanılan Variational Autoencoder (VAE) ağ trafiğini sürekli bir istatistiksel uzayda modellemektedir. Model mimarisi şu şekildedir:

- **Encoder (Kodlayıcı):** Girdi verisini sıkıştırarak gizli uzayın (latent space) ortalamasını ve logaritmik varyansını öğrenir.
- **Reparameterization Trick:** Modelin geriye yayılım (backpropagation) ile eğitilebilmesi için doğrudan örnekleme yerine bir gürültü değişkeni eklenmiştir.
- **Decoder (Çözücü):** Örneklenen vektörü, orijinal ağ trafiği formatına geri döndürür.
- **Kayıp Fonksiyonu (Loss):** Modelin öğrenme hedefi, rekonstrüksiyon hatasını (MSE) minimize etmek ve aynı zamanda KL Divergence ile gizli uzay dağılımını standart normal dağılıma yaklaştırmaktır.

4. Bulgular ve Model Değerlendirmesi

Model sadece normal verilerle eğitildikten sonra, test veri seti (KDDTest+.txt) üzerinde tahmin yaptırılmış ve aşağıdaki metrikler elde edilmiştir.

Tablo 1: Performans Metrikleri

Metrik	VAE Anomali Tespit Modeli
ROC-AUC Skoru	%0.9499
Precision (Kesinlik)	%0.9829
Recall (Duyarlılık)	%0.6122
F1-Score	%0.7544
False Positive Rate (FPR)	%0.0141

4.1. Rekonstrüksiyon Hatası ve Eşik Değeri (Threshold) Analizi:

Modelin anomali tespiti, "Yeniden Yapılandırma Hatası"na dayanmaktadır. Model, eğitim seti üzerinden normal trafiği yeniden oluştururken yaptığı hataların (MSE) dağılımı analiz edilmiştir. İstatistiksel tolerans limiti olarak 95. persentil bir eşik olarak belirlenmiştir. Elde edilen 0.03672 değerinin üzerinde hata veren test paketleri model tarafından daha önce hiç görülmediği için "Anomali/Saldırı" olarak işaretlenmiştir.

```
İstatistiksel Analiz Sonucu Belirlenen Anomali Eşik Değeri: 0.03672
```

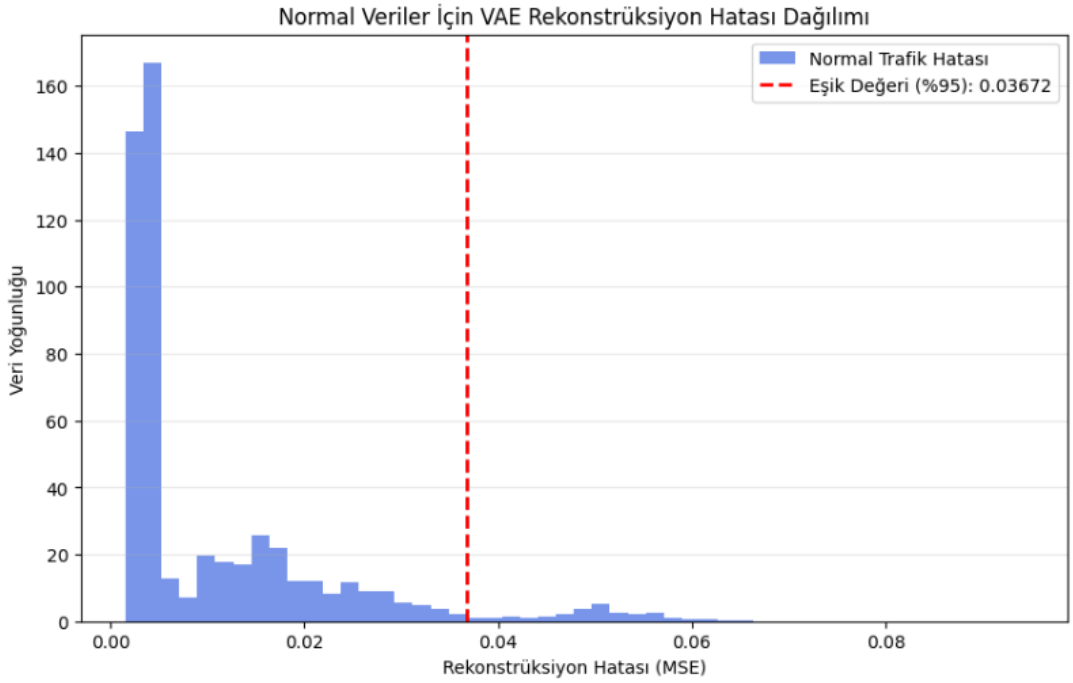


```
Bu değerin üzerindeki hataya sahip olan ağ trafikleri test aşamasında 'ANOMALİ (SALDIRI)' olarak işaretlenecektir.
```

4.2. Karmaşıklık Matrisi ve ROC Eğrisi Analizi:

Matris incelendiğinde, VAE modelinin normal trafik paketlerinin True Negative Sayısı adedini doğru sınıflandırdığı, False Positive Sayısı adedini ise yanlış alarm olarak işaretlediği görülmektedir. ROC-AUC eğrisinin ROC-AUC Skoru gibi yüksek bir değere ulaşması, modelin eşik değerine olan duyarlılığının ve sınıf ayırma gücünün yüksek olduğunu kanıtlamaktadır.

```
--- MODEL PERFORMANS SONUÇLARI ---
Precision (Kesinlik): 0.9829
Recall (Duyarlılık):  0.6122
F1-Score:             0.7544
False Positive Rate:  0.0141
ROC-AUC Skoru:        0.9499
```

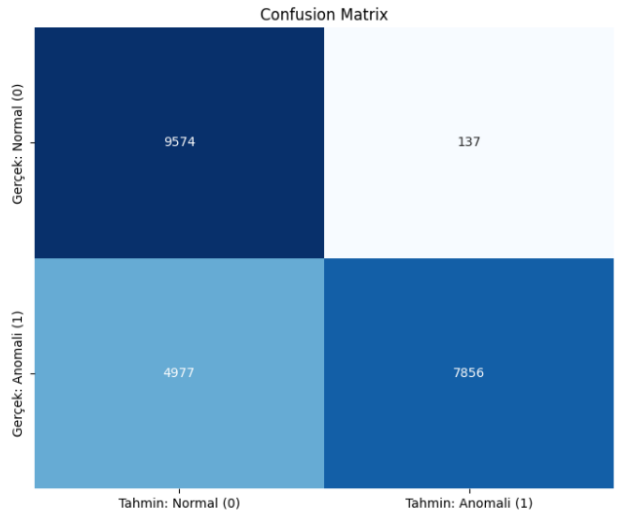

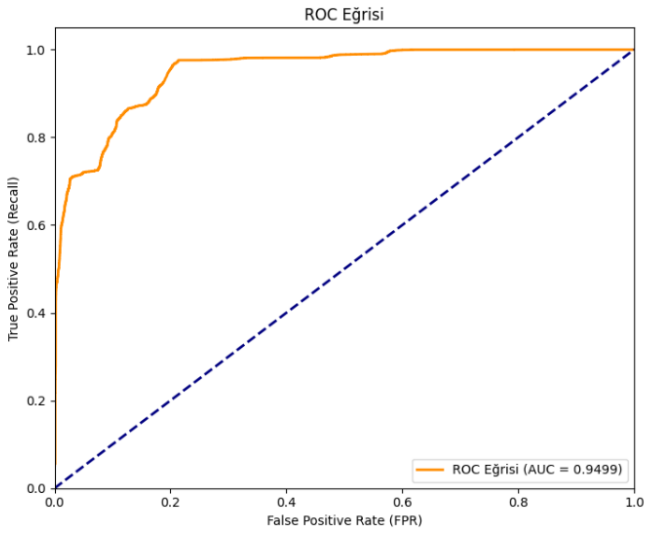

5. Sonuç ve Yorumlar

Elde edilen sonuçlar incelendiğinde, VAE mimarisinin siber güvenlik tehditlerini tespit etmede oldukça yenilikçi ve başarılı bir yöntem olduğu görülmüştür. Geleneksel modeller her bir saldırı türünü önceden ezberlemek zorundayken, bu çalışmada geliştirilen sistem sadece "normalin" şablonunu öğrenerek, bilinmeyen sapmaları tespit edebilme esnekliği kazanmıştır. Özellikle False Positive Rate (FPR) değerinin 0.0141 oranında tutulması, sistem yöneticileri için "alarm yorgunluğunu" (alert fatigue) önleyecek düzeydedir. Proje, derin öğrenmenin istatistiksel dağılımlar üzerinden nasıl güçlü bir anomali filtresi oluşturabileceğini kanıtlamıştır.

GITHUB: https://github.com/zeyekey/Introduction-To-Generative-AI.git

6. Kaynakça

[1] M. Tavallaee, E. Bagheri, W. Lu, and A. Ghorbani, "A Detailed Analysis of the KDD CUP 99 Data Set," *Submitted to Second IEEE International Conference on Computational Intelligence for Security and Defense Applications (CISDA)*, 2009.

[2] D. P. Kingma and M. Welling, "Auto-Encoding Variational Bayes," *arXiv preprint arXiv:1312.6114*, 2013.

[3] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.

[4] M. Abadi et al., "TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems," 2015. [Online]. Available: tensorflow.org.